

Beknopt maar significant* handboek voor M5 statistiek



Welk meetniveau?

Variabele
data

Categorisch ABC
*Labels, groepen,
onderscheidende
categorieën*

Continu 123
*Gemeten, schaal,
intervallen, waarden*

Nominaal

Categorieën zijn evenwaardig (= en ≠)



Ordinaal

Er is een volgorde in de categorieën (> en <)



Interval

Gelijke afstanden tussen waarden (+ en -)




Ratio

*Gelijke afstanden tussen waarden én een
absoluut 0-punt (X en /)*



Welk diagram?



Hypotheses opstellen

Een hypothese is een beknopt statement over het verwachte resultaat van een experiment of project. Er bestaan twee typen:

- de **nulhypothese** H_0 Gezien als standaard, normaal, 'wat er is' in de huidige wereld
- de **alternatieve hypothese** H_1 / H_a Wat zou kunnen zijn, iets buitengewoons, een verschil – wat zoeken of verwachten we?

→ Stel H_1 altijd als eerst op, en zet H_0 er daarna tegenover.

Voorbeeld: Een onderzoeker test de werkzaamheid van een nieuw medicijn. In een 'alternatieve' wereld zou het nieuwe medicijn iets doen, en dat hopen en verwachten we ook, dus H_1 is 'het medicijn maakt een verschil':

$H_1 = \text{het medicijn doet iets}$ OFWEL $\mu_{\text{test}} \neq \mu_{\text{control}}$

Normaal gesproken helpt een random pil echter niet, dus de normale realiteit H_0 is: het medicijn doet niets – er zijn dus geen verschillen te verwachten in de gemiddelden (μ 's) van testgroep en controlegroep, dus:

$H_0 = \text{het medicijn heeft geen effect}$ OFWEL $\mu_{\text{test}} = \mu_{\text{control}}$

De bovenstaande hypothesen hebben geen richting. Ze gaan simpelweg over een mogelijk verschil in μ 's. Deze test is **tweezijdig**. We kunnen echter ook een hypothese met een richting formuleren, in welk geval we kunnen zeggen: het medicijn *verbetert* de gezondheid. Dan testen we **éénzijdig**: het resultaat van de testgroep zou hoger moeten zijn.

$H_1 = \text{het medicijn heeft een positief effect}$ OFWEL $\mu_{\text{test}} > \mu_{\text{control}}$

Hypotheses, $\bar{x}$, μ , p , en distributie

Statistische toetsen berekenen – simpel gezegd – hoe waarschijnlijk het is dat je een resultaat zoals in je steekproef vindt (of een nog extremer resultaat), als H_0 waar zou zijn. Deze waarschijnlijkheid noemen we de p -waarde.

Waarom? Omdat we alleen voor H_1 kiezen als het gevonden verschil groot genoeg is om niet goed bij H_0 te passen.

Normaal gebruiken we een kritische p -waarde (α) van 0,05. Als $p < 0,05$, dan is ons resultaat voldoende onwaarschijnlijk onder H_0 en verwerpen we H_0 ten gunste van H_1 . Als $p \geq 0,05$, dan verwerpen we H_0 niet, omdat er onvoldoende bewijs is voor H_1 .


Een 95%-betrouwbaarheidsinterval geeft een bereik van aannemelijke waarden voor de populatieparameter die we proberen te schatten. Als de waarde van H_0 buiten het 95%-betrouwbaarheidsinterval valt, noemen we het verschil statistisch significant.


LET OP:

A. Wanneer we hypothesen over gemiddelden toetsen, gebruiken we μ (mu) voor het populatiegemiddelde. Wanneer we hypothesen over proporties (delen/aandelen) toetsen, gebruiken we π (pi) voor de populatieproportie. Hypothesen worden dus geformuleerd met μ of π .

B. μ is het werkelijke gemiddelde van de hele populatie, maar omdat populaties vaak te groot zijn om volledig te meten, is μ meestal onbekend. Daarom nemen we een steekproef en berekenen we $\bar{x}$ ($\bar{x}$), het gemiddelde van die steekproef, waarmee we μ proberen te schatten.

Als $p < \alpha$ dan verwerpen we H_0 ten gunste van H_1 . Als $p \geq \alpha$, verwerpen we H_0 niet.





Als de p-waarde van een toets lager is dan de gekozen kritische p-waarde (bijv. 0.05), dan zijn er beperkte observaties in het H_0 -gebied en kunnen we H_0 verwerpen

&

nemen we aan dat er genoeg observaties zijn in het H_1 -gebied om een verschil in μ 's aan te nemen en H_1 te ondersteunen, dus accepteren we H_1 .

- ! Als je ééNZijdig toetst, moet de p-waarde van de test worden gedeeld door 2 (je kunt de andere kant van de normaalverdeling niet 'gebruiken'). In Jamovi kun je tweezijdig of ééNZijdig aanvinken; SPSS rapporteert in de resultatentabel beide.

Error-types

Als je statistiek gebruikt om beslissingen te nemen over hypothesen, bestaat de kans dat je foute conclusies trekt. Opties zijn:

Type 1-fout, of vals-positief

H_0 verwerpen terwijl deze eigenlijk waar is en aangenomen zou moeten worden

Oftewel: H_1 accepteren terwijl je dat niet zou moeten doen

Type 2-fout, of vals-negatief

H_0 niet verwerpen terwijl deze eigenlijk onjuist is en verworpen zou moeten worden

Oftewel: H_1 niet accepteren terwijl je dat wel zou moeten doen

Type 3-fout, voor de enthousiastelingen

H_0 verwerpen en H_1 aannemen omdat de cijfers en toets dat zeggen, maar gebaseerd op foute redenering/methodologie

Voorbeeld1. Conclusie 'het medicijn verbetert de gezondheid' bij tweezijdige toetsing

Voorbeeld2. Het medicijn heeft een positief effect en mensen voelen zich beter volgens de p-waarde, maar de toets toetst niet correct het effect en de ziekte maar bijvoorbeeld meer het algemeen humeur.

Validiteit en Betrouwbaarheid

Validiteit heeft betrekking op de nauwkeurigheid van metingen: meet je wat je moet meten?

e.g. Een nieuwe vragenlijst wordt gebruikt en de resultaten komen overeen met die van eerder gebruikte vragenlijsten over hetzelfde onderwerp onder een vergelijkbare doelgroep 👍


e.g. Een thermometer wordt *naast de deur* geplaatst in een gecontroleerde laboratoriumkoelruimte 🙄

Betrouwbaarheid heeft betrekking op de consistentie van metingen en gegevens: kunnen de resultaten onder dezelfde omstandigheden worden gereproduceerd? En als de N toeneemt, wordt de uitkomst van de toets dan steeds sterker en duidelijker?


Voorbeeld1. Een respondent antwoordt 'ja' op *Eet je vlees?* en 'nee' op *Ben je vegetariër?* 👍

Voorbeeld2. Hoe meer respondenten (hogere N), hoe meer significant een gevonden verschil, hetgeen het resultaat dus versterkt


→ Interne consistentie wordt doorgaans uitgedrukt in Cronbach's alpha α




Onbetrouwbaar & niet valide



Onbetrouwbaar maar wel valide



Betrouwbaar maar niet valide




Betrouwbaar en valide

Validiteit



Betrouwbaarheid



Steekproefvorming (sampling)

- Bepaal criteria voor de doelpopulatie, bijvoorbeeld leeftijdsgrenzen of woongebied
- Vorm een steekproef van onderzoekseenheden* die zo willekeurig én representatief mogelijk is

Willekeurig, oftewel random: Ga niet zelf selectief uitzoeken, of alleen vrienden of familie vragen.

Representatief: De steekproef moet de optimale mix van kenmerken *binnen de doelpopulatie* bevatten.

A-SELECTE STEEKPROEF

Ook: **WILLEKEURIGE SELECTIE**

[probability sampling]

gebaseerd op het principe van willekeur, dus *random*: willekeurige selectie en toeval binnen een populatie of subpopulatie

SELECTE STEEKPROEF

[non-probability sampling]

Selectie wordt beïnvloed door subjectieve grenzen en/of doelgerichte, handige selectie uit de populatie of subpopulatie

*Onderzoekseenheden zijn vaak mensen, maar kunnen bijvoorbeeld ook dieren of objecten zijn.

Steekproefvorming: opties


A-SELECTE STEEKPROEF

- (SIMPLE) RANDOM
Elke willekeurige onderzoekseenheid binnen de doelgroep (random vanuit een database/lijst)
- GESTRATIFICEERD (STRATIFIED)
Verdeel de populatie in subgroepen (strata) op basis van een relevant kenmerk en trek vervolgens willekeurig een steekproef uit elke subgroep, doorgaans in dezelfde verhoudingen als in de totale populatie.
bijv. Een hbo heeft 50% Nederlandse, 20% Duitse, 20% Belgische en 10% Franse studenten.
Voor een steekproef van 1.000 studenten selecteer je willekeurig 500 Nederlandse, 200 Duitse, 200 Belgische en 100 Franse studenten.
- (GE)CLUSTERED
Verdeel de populatie in natuurlijke groepen (clusters), selecteer willekeurig een aantal van die groepen en ondervraag vervolgens iedereen (of een willekeurige steekproef van mensen) binnen de geselecteerde clusters.
bijv. Je wilt taalstudenten in heel Nederland onderzoeken, maar het is niet praktisch om elke universiteit en hogeschool te bezoeken. Je beschouwt afzonderlijke taalopleidingen of afdelingen als clusters, kiest willekeurig enkele clusters en ondervraagt alleen studenten binnen die geselecteerde afdelingen.
- SYSTEMATISCH
Op basis van een patroon, zoals elke 10^e gast

SELECTE STEEKPROEF

- SNEEUWBAL
Elke willekeurige benaderde onderzoekseenheid mag andere onderzoekseenheden benaderen
- QUOTUM
Verdeel de populatie in vaste subgroepen en selecteer uit elke subgroep een bepaald aantal mensen, zonder willekeurige selectie. Je gaat door met selecteren totdat het gewenste quotum voor elke subgroep is bereikt.
bijv. Als in een hotel 80% van de gasten in gewone kamers verblijft en 20% in suites, en je een steekproef van 50 gasten wilt, selecteer je 40 gasten uit gewone kamers en 10 gasten uit suites. Je stopt zodra deze quota zijn bereikt.
- ZELF-SELECTIE
Vrijwillige aanmelding voor deelname
- GEMAKSSTEEKPROEF
Snel en gemakkelijk: elke onderzoekseenheid die je binnen een bepaalde periode of gebied kunt vinden. Erg 'niet willekeurig'.

Welke toets?



* Bij het vergelijken van gemiddelden moet je altijd één variabele als groeperings- of factorvariabele hebben (om groepen te definiëren), die nominaal of ordinaal is. De andere (afhankelijke) variabele wordt gemeten op interval- of rationiveau.

	Test	Data checks	Resultaten
Verbanden onderzoeken	Chi² 2 categorische variabelen	Alle expected counts ≥ 5 Onafhankelijke observaties	p voor significantie Cramer's V voor sterkte (0 to 1)
	Correlation 2 continue variabelen	Lineaire data (scatterplot) Geen heftige uitbijters	p voor significantie Pearsons' r voor sterkte (-1 to 1)
Gemiddelden vergelijken	T-test 1 continue & 1 categorische variabele	Normale distributie van data Gelijke variaties (<i>homogeneity</i>)	p voor significantie Effectgrootte: Cohen's d (0 to 1) of Rank biserial correlation [-1 to 1]
	ANOVA 1 continue & 1 categorische variabele > 2 groepen	Gelijke variaties (<i>homogeneity</i>)	p voor significantie Post-hoc voor specifieke groepen Groepgemiddelden voor specificities

* Bij het vergelijken van gemiddelen moet je altijd één variabele als groeperings- of factorvariabele hebben (om groepen te definiëren), die nominaal of ordinaal is. De andere (afhankelijke) variabele wordt gemeten op interval- of rationiveau.

CHI²

- De Chi²-toets, of χ^2 -toets, wordt gebruikt om te kijken of er een verband bestaat tussen twee categorische variabelen.
- Omdat categorische variabelen geen numerieke metingen hebben en daarom niet met behulp van gemiddelden kunnen worden geanalyseerd, werkt Chi² met frequenties om te zien of er verschillen zijn tussen geobserveerde data (de metingen) en de verwachte metingen (*expected counts*).
- De *expected counts* voor alle cellen moeten minimaal 5 zijn en wordt berekend met behulp van de formule $(\text{rowtotal} \times \text{columntotal}) / N$, bijvoorbeeld $(28 \times 32) / 106$ voor cel **1-NO** in de tabel hieronder
- Je vindt de Chi2-test in Jamovi onder Analyses > Frequencies > Independent Samples χ^2 of association
- Jamovi maakt een kruistabel met de χ^2 -testresultaten en Cramer's V (indien geselecteerd onder *Statistics*)

Contingency Tables

qualification		healthplan		Total
		No	Yes	
1	Observed	12	16	28
	Expected	8.45	19.55	28.00
2	Observed	18	27	45
	Expected	13.58	31.42	45.00
3	Observed	0	8	8
	Expected	2.42	5.58	8.00
4	Observed	2	18	20
	Expected	6.04	13.96	20.00
5	Observed	0	5	5
	Expected	1.51	3.49	5.00
Total	Observed	32	74	106
	Expected	32	74	106

χ^2 Tests


	Value	df	p
χ^2	13.7	4	0.008
N	106		

Nominal

	Value
Phi-coefficient	NaN
Cramer's V	0.359

CORRELATIE

- De correlatietest wordt gebruikt om te zien of er een relatie is tussen twee continue variabelen
- Voor data-checks ga je in Jamovi naar Exploration > Scatterplot om te zien of de data redelijkerwijs lineair zijn
- Je vindt de correlatietest in Jamovi onder Analyses > Regressie > Correlatiematrix
- Jamovi maakt een correlatiematrix met de uitkomsten, waaronder Pearson's r



Correlation Matrix

		age	seniority
age	Pearson's r	—	
	df	—	
	p-value	—	
seniority	Pearson's r	0.882	—
	df	104	—
	p-value	<.001	—

T-TEST

- De T-test wordt gebruikt om de gemiddelden (μ 's) van 2 groepen voor een continue afhankelijke variabele te vergelijken, om te zien of er een significant verschil is tussen de groepen. Er zijn 3 soorten T-test:
 - One sample t-test.** Wordt gebruikt om de μ van je verzamelde data te vergelijken met een al bestaande μ (bijvoorbeeld uit de literatuur)
 - Independent t-test.** Wordt gebruikt om de μ 's van twee groepen die je zelf hebt geobserveerd te vergelijken
 - Paired samples t-test.** Wordt gebruikt om de μ 's van gegevens die binnen één groep zijn verzameld, maar op twee verschillende momenten te vergelijken (bijv. μ hartslag vóór en μ ná het drinken van koffie). ¡Hiervoor zijn dezelfde mensen in beide groepen nodig!
- Hier moet je duidelijk éénzijdige of tweezijdige hypothesen opstellen om de juiste instellingen te kiezen en resultaten correct te interpreteren. Bij éénzijdig testen geldt slechts de helft van de berekende p-waarde. Jamovi verandert automatisch de p wanneer je éénzijdig aanvinkt; in SPSS zou je kolom ´ éénzijdig ´ moeten uitlezen.
- T-tests vindt je in Jamovi onder Analyses > T-tests.
- Om de data-checks te doen, kies je in Jamovi de *Homogeneity* (Levene's) en de *Normality* (Shapiro-Wilk).
 - Als beide p-waarden **hoger** zijn dan 0.05 kun je doorgaan met een normale T-test (Student's t).
 - Als één van beide niet ok is, of als beide niet ok zijn, moet je de optie *Mann-Whitney U* aanvinken en doorgaan (De Mann-Whitney U gebruikt medianen in plaats van gemiddelden)
- Voor effectgrootte vink je aan *Effect Size* onder *Additional Statistics*. Hiermee worden Cohen's d (van toepassing bij het uitvoeren van een normale t-test) en Rank biserial correlation (van toepassing bij het uitvoeren van de Mann-Whitney U) toegevoegd.

Normality Test (Shapiro-Wilk)		
	W	p
perf_quantity	0.979	0.094

Note. A low p-value suggests a violation of the assumption of normality

Homogeneity of Variances Test (Levene's)				
	F	df	df2	p
perf_quantity	0.256	1	104	0.614

Note. A low p-value suggests a violation of the assumption of equal variances

Independent Samples T-Test				
		Statistic	df	p
perf_quantity	Student's t	1.43	104	0.157

Note. $H_a: \mu_2 \neq \mu_1$

Effect Size	
Cohen's d	0.383
Rank biserial correlation	-0.206

ANOVA

- ANOVA wordt gebruikt om gemiddelden (μ 's) van 3 of meer groepen voor een continue afhankelijke variabele te vergelijken, om te zien of er een significant verschil is tussen die groepen. Je moet 2 opties voor ANOVA kennen, waarvoor de keuze is gebaseerd op Levene's test van homogeniteit (data-check).
 - ANOVA Fisher's test.** Wordt gebruikt als er aan homogeniteit wordt voldaan (dus: Levene's $p > 0.05$)
 - ANOVA Welch test.** Wordt gebruikt als er **niet** aan homogeniteit wordt voldaan (dus: Levene's $p < 0.05$)
 - Je vindt ANOVA in Jamovi onder Analyses > ANOVA > One-way ANOVA.
 - Om de homogeniteit te controleren vink je in Jamovi binnen de ANOVA aan *Homogeneity test* (Levene's)
- Maar.... als er een significant verschil wordt gevonden, moeten we nog steeds kijken tussen welke groepen dat verschil bestaat, waarvoor we post-hoc-tests gebruiken. Deze post-hoc-tests tonen p-waarden voor specifieke combinaties van groepen, zodat je de resultaten nauwkeuriger kan rapporteren. Om ook te kunnen rapporteren welke groepen hoger scoren dan anderen, bekijk je beschrijvende statistieken (*descriptives*) om de gemiddelen van de groepen te zien. Post-hoc-opties zijn:
- Voor de ANOVA Welch test gebruiken we de Games-Howell
 - Voor de ANOVA Fisher's test gebruiken we de Bonferroni of Tukey, waarbij de keuze afhankelijk is van aanvaardbare risico's:
 - Bonferroni is vrij strikt, wat betekent dat de kans op een type I-fout kleiner is, maar de kans op een type II-fout groter is
 - Tukey is minder strikt, wat betekent dat de kans op een type I-fout groter is, maar de kans op een type II-fout kleiner. Jamovi heeft alleen Tukey.

Assumption Checks

Homogeneity of Variances Test (Levene's)			
	F	df1	df2
perf_quantity	1.68	4	101

One-Way ANOVA				
	F	df1	df2	p
perf_quantity	Welch's 8.00	4	20.0	<.001
	Fisher's 4.18	4	101	0.004

Tukey Post-Hoc Test – perf_quantity						
		1	2	3	4	5
1	Mean difference	—	0.365	1.132	−0.439	−1.136
	p-value	—	0.734	0.156	0.742	0.324
2	Mean difference		—	0.767	−0.804	−1.501
	p-value		—	0.486	0.117	0.081
3	Mean difference			—	−1.571	−2.268
	p-value			—	0.024	0.014
4	Mean difference				—	−0.697
	p-value				—	0.789
5	Mean difference					—
	p-value					—

NOTITIES

